

**Санкт-Петербургский
Политехнический университет Петра Великого**

**Отчет по лабораторной работе №3. Боксплот Тьюки и
анализ выбросов**

Студент: Бурачевский Е.А.

Преподаватель: Баженов А.Н.

Группа: 5030102/30202

Санкт-Петербург

2025

Содержание

1	Формулировка задачи	3
2	Теоретическая часть	3
2.1	Используемые распределения	3
2.2	Боксплот Тьюки	3
3	Реализация	3
4	Результаты	4
5	Обсуждение	6
6	Вывод	7
7	Список литературы	7
8	Приложение	7

1 Формулировка задачи

Сгенерировать выборки объемом $n = 20$ и $n = 100$ для каждого из пяти распределений. Для каждой выборки построить боксплот Тьюки. Экспериментально определить долю выбросов: для каждого распределения сгенерировать 1000 выборок заданного объема, вычислить долю выбросов в каждой выборке и найти среднее значение.

Цели и задачи:

- научиться применять боксплот Тьюки для обработки и анализа одномерных распределений;
- проанализировать, как размер выборки влияет на долю отсеиваемых аномальных значений.

2 Теоретическая часть

2.1 Используемые распределения

В работе исследуются нормальное распределение $N(0, 1)$, распределение Коши $C(0, 1)$, распределение Лапласа $L(0, 1/\sqrt{2})$, распределение Пуассона $P(10)$ и равномерное распределение $U(-\sqrt{3}, \sqrt{3})$.

2.2 Боксплот Тьюки

Боксплот Тьюки строится по квартилям выборки. Пусть $Q1$ — первый квартиль, $Q2$ — медиана, $Q3$ — третий квартиль. Межквартильный размах определяется как $IQR = Q3 - Q1$. Границы допустимых значений задаются выражениями $Q1 - 1.5 IQR$ и $Q3 + 1.5 IQR$. Значения, выходящие за эти границы, считаются выбросами.

Практическая доля выбросов в выборке объема n вычисляется как отношение количества элементов, отмеченных правилом Тьюки как выбросы, к общему числу элементов выборки. В эксперименте эта доля усредняется по 1000 повторным генерациям.

3 Реализация

Используемый язык программирования: Python 3.12.

Используемые библиотеки: numpy, Pillow, reportlab.

Описание реализованных функций:

- `get_generators(rng)` — создаёт генераторы пяти исследуемых распределений;
- `calculate_tukey_boxplot(sample)` — вычисляет квартили, межквартильный размах, границы Тьюки, усы и список выбросов;
- `calculate_outlier_share(sample)` — вычисляет долю выбросов в одной выборке;
- `estimate_average_outlier_share(generator, n, repeats)` — находит среднюю долю выбросов по 1000 повторным выборкам;
- `draw_boxplots(dist_name, samples, sizes, output_path)` — строит и сохраняет боксплоты для выборок объема $n = 20$ и $n = 100$;
- `main()` — запускает эксперимент, печатает итоговую таблицу и сохраняет графики.

4 Результаты

Таблица 1: Средняя доля выбросов по правилу Тьюки

Распределение	n = 20	n = 100
Нормальное	0.0219	0.0100
Коши	0.1522	0.1546
Лапласа	0.0739	0.0660
Пуассона	0.0264	0.0111
Равномерное	0.0018	0.0000

4.1 Нормальное распределение

Нормальное распределение




Рис. 1: Боксплоты для нормального распределения

4.2 Распределение Коши

Распределение Коши




Рис. 2: Боксплоты для распределения Коши

4.3 Распределение Лапласа

Распределение Лапласа




Рис. 3: Боксплоты для распределения Лапласа

4.4 Распределение Пуассона

Распределение Пуассона




Рис. 4: Боксплоты для распределения Пуассона

4.5 Равномерное распределение

Равномерное распределение




Рис. 5: Боксплоты для равномерного распределения

5 Обсуждение

Наибольшая средняя доля выбросов наблюдается у распределения Коши: около 0.15 для обоих объёмов выборки. Это связано с тяжёлыми хвостами распределения: крайние значения появляются часто и регулярно попадают за границы $Q1 - 1.5 IQR$ и $Q3 + 1.5 IQR$.

У распределения Лапласа доля выбросов меньше, чем у распределения Коши, но заметно выше, чем у нормального распределения. Это соответствует более резкому пику и более тяжёлым хвостам распределения Лапласа по сравнению с нормальным.

Для нормального и пуассоновского распределений при увеличении объёма выборки с 20 до 100 средняя доля выбросов уменьшается. Для равномерного распределения выбросы практически отсутствуют, поскольку распределение ограничено на конечном отрезке.

Полученные результаты показывают, что боксплот Тьюки хорошо выявляет распределения с тяжёлыми хвостами и позволяет наглядно сравнивать устойчивость выборок разных типов.

6 Вывод

В результате выполнения лабораторной работы были построены боксплоты Тьюки для выборок объёма $n = 20$ и $n = 100$, а также экспериментально оценена средняя доля выбросов для пяти распределений. Было установлено, что наибольшая доля выбросов характерна для распределения Коши, а наименьшая — для равномерного распределения.

Размер выборки влияет на устойчивость оценки доли выбросов, однако основное различие определяется видом распределения и поведением его хвостов. Поставленная цель работы достигнута.

7 Список литературы

1. Тьюки Дж. Анализ результатов наблюдений. Разведочный анализ. — М.: Мир, 1981.
2. Крамер Г. Математические методы статистики. — М.: Мир, 1975.
3. Документация NumPy: <https://numpy.org/doc/>

8 Приложение

Ссылка на репозиторий GitHub с исходным кодом программы:
<https://github.com/R9quiem/mat.-stat.-labs/tree/main/lab%203>